

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP LỚN
MÔN HỌC
HỌC MÁY - CO3117

ĐỀ TÀI

PHÁT HIỆN TIN TUYỂN DỤNG CÓ DẤU HIỆU LỪA ĐẢO:
TỪ PIPELINE HỌC MÁY TRUYỀN THỐNG ĐẾN
MỞ RỘNG HỌC SÂU TEXTCNN

Giảng viên hướng dẫn: TS. Trương Vĩnh Lân

Lớp: A01

Nhóm: 01

Thành phố Hồ Chí Minh, tháng 09 năm 2026



DANH SÁCH THÀNH VIÊN

STT	MSSV	Họ và tên	Công việc	Đóng góp
1	2352171	Dương Lê Nhật Duy	Xây dựng pipeline chính; làm sạch, nhóm trùng, chia train/validation/test; kiểm soát leakage và tích hợp.	100%
2	2352715	Trần Thiên Lộc	Khảo sát EMSCAD, thực hiện EDA; xây dựng BoW/TF-IDF, biểu đồ dữ liệu và tổng hợp cơ sở lý thuyết.	100%
3	2352937	Nguyễn Huy Phúc	Thử nghiệm Naive Bayes, Logistic Regression, Linear SVM và GloVe; chọn cấu hình/ngưỡng trên validation, lập bảng so sánh.	100%
4	2353350	Đinh Đoàn Vy	Xây dựng TextCNN, phân tích lỗi và demo; kiểm thử notebook Run all, đóng gói artifact và hoàn thiện báo cáo.	100%

MỤC LỤC

TÓM TẮT	3
1 Giới thiệu chung	4
1.1 Bài toán phát hiện tin tuyển dụng lừa đảo	4
1.2 Mục tiêu và phạm vi	4
1.3 Nội dung thực hiện	4
1.4 Câu hỏi nghiên cứu	5
2 Dữ liệu và biểu diễn văn bản	6
2.1 Nguồn dữ liệu EMSCAD và phân chia tập	6
2.2 Chất lượng dữ liệu và quyết định xử lý	7
2.3 Khám phá dữ liệu	8
2.4 Đại diện đặc trưng: Bag-of-Words và TF-IDF	8
2.5 Đại diện ngữ nghĩa: GloVe pooling	9
2.6 Artifact đặc trưng và căn chỉnh hàng	10
2.7 Mô hình phân loại và tiêu chí đánh giá	10
3 Xây dựng pipeline và thiết kế thực nghiệm	12
3.1 Kiến trúc pipeline đầu-cuối	12
3.2 Tiền xử lý và kiểm soát rò rỉ dữ liệu	12
3.3 Các cấu hình được so sánh	14
3.4 Kết quả sàng lọc trên validation	14
3.5 Mở rộng học sâu với TextCNN	15
3.6 Môi trường chạy và khả năng tái lập	16
4 Kết quả, so sánh và phân tích	17
4.1 Chọn mô hình trên validation	17
4.2 Đánh giá cuối cùng trên tập test	17
4.3 Độ ổn định từ validation sang test	18
4.4 Đánh đổi giữa mô hình, chất lượng và tài nguyên	19
4.5 Phân tích precision-recall và ma trận nhầm lẫn	19
4.6 Diễn giải kết quả so sánh biểu diễn	21
4.7 Phân tích lỗi	21
5 Demo, ứng dụng và giới hạn	23
5.1 Demo suy luận và giải thích	23
5.2 Kịch bản sử dụng đề xuất	23
5.3 Giới hạn và nguyên tắc sử dụng có trách nhiệm	23
6 Kết luận và hướng phát triển	25
7 Các đường link	26
TÀI LIỆU THAM KHẢO	27

TÓM TẮT

Tin tuyển dụng trực tuyến giả mạo gây thiệt hại cho người tìm việc thông qua đánh cắp thông tin, thu phí trái phép hoặc dẫn dụ vào những hoạt động không minh bạch. Báo cáo xây dựng một pipeline học máy có thể tái lập để nhận diện tin tuyển dụng tiếng Anh có dấu hiệu lừa đảo trên bộ EMSCAD. Nghiên cứu so sánh Bag-of-Words, TF-IDF và embedding GloVe 50 chiều với các bộ phân loại truyền thống, đồng thời bổ sung TextCNN học embedding end-to-end để đối chiếu với pipeline học sâu.

Quy trình đặc biệt chú trọng kiểm soát rò rỉ dữ liệu. Các bản sao văn bản chính xác được loại bỏ, còn những tin có phần mô tả hoặc hồ sơ công ty trùng nhau được gom nhóm trước khi chia train/validation/test. Toàn bộ từ điển, trọng số IDF, scaler và ngưỡng quyết định chỉ được fit hoặc lựa chọn từ train và validation. Tổng cộng 26 cấu hình truyền thống được đánh giá; mô hình tốt nhất là TF-IDF unigram+bigram kết hợp Linear SVM. TextCNN được chọn epoch và ngưỡng riêng trên validation trước khi đánh giá test.

Trên tập test gồm 3.175 tin, mô hình đạt accuracy 0,9609, precision lớp gian lận 0,5714, recall 0,5315, F1 0,5507 và average precision 0,5348. Ma trận nhầm lẫn gồm 2.975 TN, 57 FP, 67 FN và 76 TP. Kết quả cho thấy TF-IDF phù hợp với bài toán hơn GloVe pooling đơn giản, nhưng hệ thống vẫn bỏ sót 67/143 tin gian lận. Vì vậy mô hình chỉ nên được xem như công cụ sàng lọc hỗ trợ, không phải bằng chứng pháp lý hoặc cơ chế tự động kết luận một tổ chức có hành vi gian lận.

Từ khóa: phát hiện gian lận, tin tuyển dụng, phân loại văn bản, TF-IDF, GloVe, Linear SVM, TextCNN, dữ liệu mất cân bằng.

1 Giới thiệu chung

1.1 Bài toán phát hiện tin tuyển dụng lừa đảo

Sự phát triển của các nền tảng tuyển dụng trực tuyến giúp kết nối doanh nghiệp và người lao động nhanh chóng, đồng thời tạo điều kiện cho các tin giả mạo lan truyền với chi phí thấp. Người tìm việc thường phải cung cấp thông tin cá nhân và có thể bị dẫn dụ thanh toán trước, chuyển tiền, mua thiết bị hoặc tham gia những quy trình tuyển dụng không tồn tại. Việc rà soát thủ công toàn bộ tin đăng không mở rộng tốt, vì vậy phân loại văn bản là một hướng hỗ trợ sàng lọc phù hợp.

Bài toán có hai thách thức chính. Thứ nhất, lớp gian lận rất hiếm: trong dữ liệu gốc chỉ có 866/17.880 tin, tương đương 4,84%. Thứ hai, nhiều tin lặp lại phần mô tả hoặc hồ sơ công ty. Nếu các bản gần như trùng nhau xuất hiện ở cả train và test, chỉ số đánh giá có thể bị thổi phồng do mô hình ghi nhớ nội dung thay vì học tín hiệu tổng quát.

1.2 Mục tiêu và phạm vi

Nghiên cứu hướng đến bốn mục tiêu:

1. Xây dựng pipeline tiền xử lý và chia dữ liệu có kiểm soát trùng lặp.
2. So sánh BoW/TF-IDF với embedding GloVe trong cùng giao thức đánh giá.
3. Lựa chọn cấu hình và ngưỡng trên validation trước khi đánh giá test.
4. Phân tích lỗi và nêu rõ giới hạn để tránh diễn giải quá mức.

Phạm vi của báo cáo là phân loại nhị phân từ nội dung tin đăng, không suy diễn về uy tín pháp lý của doanh nghiệp hay xác minh danh tính nhà tuyển dụng. Các chỉ số được dùng để so sánh trong cùng bộ dữ liệu và cùng cách chia tập; vì vậy chúng phản ánh chất lượng thực nghiệm của pipeline hơn là một cam kết hiệu quả cho mọi nền tảng tuyển dụng.

1.3 Nội dung thực hiện

Đóng góp của dự án gồm: pipeline đầu-cuối có thể chạy bằng terminal hoặc notebook; 26 cấu hình truyền thống và một pipeline TextCNN; artifact đặc trưng và mô hình được lưu kèm checksum; dự đoán từng mẫu để tính lại chỉ số độc lập; biểu đồ, ma trận nhầm lẫn và danh sách lỗi cho từng họ mô hình; cùng một demo giải thích dự đoán của mô hình tuyến tính.

Các thành phần được tách rõ theo dữ liệu đầu vào, tiền xử lý, tạo đặc trưng, huấn luyện và đánh giá. Cách tổ chức này giúp việc thay một biểu diễn hoặc một bộ phân loại không làm thay đổi giao thức chia dữ liệu, đồng thời giúp đổi chiều lại kết quả khi chạy lại notebook hoặc lệnh dòng lệnh.

1.4 Câu hỏi nghiên cứu

Báo cáo trả lời bốn câu hỏi thực nghiệm.

- **RQ1:** Biểu diễn thưa truyền thống hay embedding liên tục phù hợp hơn với EMSCAD?
- **RQ2:** Bigram, loại stopwords và độ mạnh regularization ảnh hưởng như thế nào tới lớp gian lận?
- **RQ3:** TextCNN học end-to-end có vượt được mô hình tuyến tính trên dữ liệu mất cân bằng hay không?
- **RQ4:** Mô hình sai ở đâu và cần điều kiện gì trước khi được dùng như một bộ lọc hỗ trợ?

Giá trị của nghiên cứu không chỉ nằm ở một điểm F1. Pipeline lưu lại nguồn dữ liệu, checksum, thứ tự hàng, cấu hình, ngưỡng, dự đoán và lỗi của từng mô hình. Nhờ đó, mọi bảng số liệu trong báo cáo đều có thể truy ngược về artifact thay vì được chép thủ công hoặc chọn sau khi quan sát test. Đây là yếu tố quan trọng để một bài tập mô hình hóa trở thành một thí nghiệm học máy có thể kiểm chứng.

2 Dữ liệu và biểu diễn văn bản

2.1 Nguồn dữ liệu EMSCAD và phân chia tập

EMSCAD là bộ tin tuyển dụng tiếng Anh lịch sử giai đoạn 2012–2014 [1]. Dữ liệu gốc gồm 17.880 dòng và nhãn nhị phân *fraudulent*, trong đó nhãn 1 biểu thị tin gian lận. Văn bản đầu vào được ghép từ năm trường: tiêu đề, hồ sơ công ty, mô tả, yêu cầu và quyền lợi. Các trường định danh như *job_id*, nhãn hoặc kết quả dự đoán không được dùng làm đặc trưng.


Nguồn dữ liệu được tải tự động từ địa chỉ công khai trong notebook; checksum của file thô được ghi vào manifest để phát hiện thay đổi ngoài ý muốn. Năm trường văn bản được chọn vì có thể áp dụng nhất quán cho mọi tin. Những trường như logo, câu hỏi sàng lọc, địa điểm hay loại việc làm không được đưa vào phiên bản text-only, nhờ đó phép so sánh tập trung vào năng lực của biểu diễn văn bản thay vì trộn lẫn tín hiệu metadata.

Nhóm trường	Cách sử dụng	Lý do
Title, company profile, description, requirements, benefits	Ghép thành văn bản đầu vào	Chứa ngữ nghĩa mô tả công việc và lời mời tuyển dụng.
Fraudulent	Chỉ dùng làm nhãn	Tuyệt đối không xuất hiện trong đặc trưng.
Job ID	Theo dõi mẫu và phân tích lỗi	Không mang ý nghĩa ngữ nghĩa; loại khỏi đặc trưng.
Logo, questions, location, industry, function	Không dùng trong bản text-only	Giữ phép so sánh biểu diễn văn bản công bằng và tránh mở rộng ngoài phạm vi.

Bảng 1: Vai trò của các nhóm trường trong EMSCAD

Trạng thái dữ liệu	Số mẫu	Số gian lận
Dữ liệu gốc	17.880	866
Sau loại trùng văn bản	15.872	713
Train	9.522	427
Validation	3.175	143
Test	3.175	143

Bảng 2: Quy mô dữ liệu và các tập chia



Hình 1: Tổng quan phân bố nhãn và dữ liệu thiếu

2.2 Chất lượng dữ liệu và quyết định xử lý

Tỷ lệ gian lận của dữ liệu gốc là 4,84%; sau làm sạch, mỗi tập validation/test có 143 mẫu gian lận trong tổng số 3.175 mẫu. Do đó, một mô hình luôn đoán *hợp lệ* vẫn đạt xấp xỉ 95,50% accuracy. Đây là lý do báo cáo xem F1 lớp gian lận và average precision là hai chỉ số chính.

Trường	Thiếu	Trường	Thiếu
Location	346	Company profile	3.308
Department	11.547	Description	1
Salary range	15.012	Requirements	2.696
Benefits	7.212	Employment type	3.471
Required experience	7.050	Required education	8.105
Industry	4.903	Function	6.455

Bảng 3: Một số trường thiếu đáng chú ý trong dữ liệu gốc

Các trường văn bản thiếu sẽ được thay bằng chuỗi rỗng trước khi ghép; không suy diễn nội dung không tồn tại và không dùng nhãn để điền. Description thiếu duy nhất một dòng nên không cần loại mẫu. Hai nghìn lẻ tám bản sao văn bản chính xác được loại trước khi chia tập; quy tắc nhóm nội dung sau đó xử lý thêm nguy cơ trùng description hoặc company profile giữa các tập.

2.3 Khám phá dữ liệu

Phân tích EDA được thực hiện trên tập train sau khi chia nhóm nhằm tránh sử dụng thống kê test để định hướng mô hình. Hình 2 cho thấy phân bố độ dài văn bản và quy mô từng tập. Bảng 4 liệt kê tám từ xuất hiện nhiều nhất của mỗi lớp; các từ phổ biến như *work*, *experience* và *team* có mặt ở cả hai lớp, cho thấy một từ đơn lẻ không đủ để kết luận gian lận và tạo động lực thử thêm bigram.

Hợp lệ (nhãn 0)		Gian lận (nhãn 1)	
Từ	Số lần	Từ	Số lần
experience	21.920	work	952
work	18.585	experience	893
team	17.977	team	579
company	13.043	skills	514
business	11.405	engineering	505
skills	10.473	company	489
new	10.087	project	448
development	9.878	solutions	431

Bảng 4: Các từ có tần suất cao nhất trên tập train

Phân vị	Số token	Phân vị	Số token
Min	2	50%	372
25%	246	75%	507
95%	762	Max	2.118

Bảng 5: Phân vị độ dài văn bản trên tập train

Trung vị 372 token cho thấy phần lớn tin có đủ nội dung để mô hình hóa, trong khi đuôi dài lên tới 2.118 token giải thích vì sao cần giới hạn độ dài ở pipeline dense/deep learning. EDA tần suất từ chỉ dùng train để tránh nhìn trước phân bố test. Việc nhiều từ phổ biến xuất hiện ở cả hai lớp cũng gợi ý rằng mô hình cần học tổ hợp từ và trọng số theo ngữ cảnh cục bộ, thay vì tạo luật dựa trên một từ khóa đơn lẻ.

2.4 Đại diện đặc trưng: Bag-of-Words và TF-IDF

Bag-of-Words biểu diễn tài liệu bằng số lần xuất hiện của từ. Với TF-IDF, tần suất từ được giảm trọng số nếu từ xuất hiện trong nhiều tài liệu.

Một dạng phổ biến của TF-IDF [5, 11] là

$$\text{tfidf}(t, d) = \text{tf}(t, d) \log \left(\frac{N + 1}{\text{df}(t) + 1} \right), \quad (1)$$

trong đó N là số tài liệu train và $\text{df}(t)$ là số tài liệu train chứa từ t . Nghiên cứu thử unigram, unigram+bigram và biến thể bỏ English stopwords; số chiều tối đa là 40.000.

Từ điển TF-IDF chỉ được fit trên tập train, sau đó giữ cố định khi biến đổi validation và test. Việc giới hạn số chiều giúp giảm chi phí bộ nhớ nhưng vẫn cho phép giữ các cụm từ xuất hiện đủ thường xuyên. So sánh unigram với unigram+bigram cũng kiểm tra trực tiếp liệu thông tin của cụm từ có mang lại lợi ích hơn so với từng từ riêng lẻ hay không.

2.5 Đại diện ngữ nghĩa: GloVe pooling

GloVe ánh xạ mỗi từ vào vector liên tục dựa trên thống kê đồng xuất hiện [2]. Dự án sử dụng bộ glove-wiki-gigaword-50 gồm 400.000 từ, 50 chiều, giữ cố định trong quá trình huấn luyện. Vector tài liệu được tạo theo hai cách:

$$\mathbf{v}_{mean}(d) = \frac{1}{|K_d|} \sum_{t \in K_d} \mathbf{e}_t, \quad (2)$$

$$\mathbf{v}_{idf}(d) = \frac{\sum_{t \in K_d} \text{idf}(t) \mathbf{e}_t}{\sum_{t \in K_d} \text{idf}(t)}, \quad (3)$$

với K_d là các token của tài liệu có mặt trong từ điển GloVe. Trọng số IDF chỉ được fit trên train. Tài liệu bị giới hạn 1.500 token; có 17 tài liệu bị cắt, độ phủ token trung bình đạt 96,28% và không có tài liệu nào tạo vector không.

Hai cách pooling được giữ trong cùng một pipeline để việc so sánh tập trung vào biểu diễn văn bản thay vì khác biệt trong dữ liệu đầu vào. Các token không có trong từ điển GloVe không góp vào vector tài liệu; do đó độ phủ token được ghi lại như một chỉ dấu cho lượng thông tin bị mất. GloVe được giữ cố định nhằm bảo đảm phép thử tái lập và tránh đưa thêm bước fine-tune ngoài phạm vi mô hình truyền thống.

2.6 Artifact đặc trưng và căn chỉnh hàng

Đề bài yêu cầu lưu embedding hoặc vector đặc trưng. Dự án lưu cả ma trận thưa, ma trận dense và tensor token; mọi artifact dùng chung các mảng `job_ids.npy`, `labels.npy` và `splits.npy` để giữ đúng thứ tự hàng. Manifest chứa shape, dtype và checksum giúp phát hiện việc trộn nhầm đặc trưng với nhãn.

Artifact	Dung lượng	Nội dung
<code>bow.npz</code>	6,43 MB	Ma trận Bag-of-Words thưa.
<code>tfidf_uni.npz</code>	16,58 MB	TF-IDF unigram.
<code>tfidf_bi.npz</code>	32,02 MB	TF-IDF unigram+bigram.
<code>tfidf_bi_stop.npz</code>	19,15 MB	TF-IDF bigram có loại stopwords.
<code>glove_mean.npy</code>	3,17 MB	Vector GloVe mean pooling 50 chiều.
<code>glove_idf.npy</code>	3,17 MB	Vector GloVe IDF pooling 50 chiều.
<code>textcnn_token_ids.npy</code>	38,09 MB	Chuỗi token ID đã padding cho TextCNN.

Bảng 6: Các file đặc trưng được lưu để nộp và tái sử dụng

2.7 Mô hình phân loại và tiêu chí đánh giá

BoW được kết hợp với Multinomial Naive Bayes. TF-IDF và GloVe được đánh giá với Logistic Regression và Linear SVM, sử dụng trọng số lớp cân bằng. Vì dữ liệu lệch lớp mạnh, accuracy không đủ phản ánh chất lượng. Báo cáo tập trung vào precision, recall, F1 của lớp gian lận và average precision (AP):

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}. \quad (4)$$

Precision cho biết mức độ đáng tin của một cảnh báo, trong khi recall phản ánh khả năng phát hiện các tin gian lận đã biết. F1 cân bằng hai đại lượng này tại một ngưỡng cụ thể; AP đánh giá khả năng xếp hạng trên nhiều ngưỡng nên đặc biệt hữu ích khi lớp gian lận hiếm [13]. Mọi lựa chọn mô hình và ngưỡng đều được thực hiện trên validation, còn test chỉ dùng cho báo cáo cuối cùng.

Ba bộ phân loại được chọn vì tạo ra một dải giả định khác nhau. MultinomialNB phù hợp với số đếm không âm và tạo baseline xác suất nhanh. Logistic Regression tối ưu log-loss và cung cấp score có thứ tự liên tục. Linear SVM tối đa hóa biên phân tách trong không gian nhiều

chiều [12], rất phù hợp với ma trận TF-IDF thưa. Với LR/SVM, `class_weight=balanced` tăng trọng số lớp gian lận theo tần suất nghịch đảo mà không thay đổi phân bố test.

$$\hat{y} = \mathbb{I}[s(\mathbf{x}) \geq \tau], \quad (5)$$

trong đó $s(\mathbf{x})$ là score của mô hình và τ là ngưỡng được tìm duy nhất trên validation. Việc tách score khỏi ngưỡng cho phép lựa chọn điểm vận hành phù hợp lớp hiếm, đồng thời tránh hiểu sai ngưỡng mặc định 0 hoặc 0,5 là tối ưu cho F1.

3 Xây dựng pipeline và thiết kế thực nghiệm

3.1 Kiến trúc pipeline đầu-cuối

Pipeline được hiện thực theo bảy bước có đầu vào và đầu ra rõ ràng. Mỗi bước ghi artifact cần thiết để có thể kiểm tra độc lập thay vì chỉ giữ mô hình cuối.

Bước	Thành phần	Kết quả được lưu
1	Tải và xác minh dữ liệu	CSV gốc, URL nguồn, SHA-256, số dòng và phân bố nhãn.
2	Làm sạch và audit	Văn bản chuẩn hóa, số bản trùng, thống kê missing và quy tắc nhóm.
3	Chia dữ liệu theo nhóm	Manifest train/validation/test; một nhóm không xuất hiện ở hai tập.
4	Tạo đặc trưng	Các file NPZ/NPY, vocabulary, scaler/IDF và manifest căn chỉnh hàng.
5	Huấn luyện	26 cấu hình truyền thống và TextCNN với seed cố định.
6	Chọn trên validation	Cấu hình, epoch và ngưỡng theo F1; AP dùng làm tie-break.
7	Đánh giá khóa	Bảng test, dự đoán từng mẫu, PR curve, confusion matrix và danh sách lỗi.

Bảng 7: Luồng xử lý và artifact tại từng bước

Train chịu trách nhiệm học tham số và thống kê biểu diễn; validation dùng để lựa chọn siêu tham số, epoch và ngưỡng; test chỉ được mở sau khi quyết định đã khóa. Phân vai này được dùng nhất quán cho cả pipeline truyền thống và TextCNN, giúp so sánh công bằng và hạn chế tối ưu gián tiếp theo test.

3.2 Tiền xử lý và kiểm soát rò rỉ dữ liệu

Pipeline HTML-decode, bỏ thẻ, chuyển chữ thường, chuẩn hóa khoảng trắng và thay URL/email bằng token; các từ phủ định được giữ lại. Sau khi ghép năm trường văn bản, 2.008 bản sao văn bản chính xác được loại bỏ.


Các lựa chọn tiền xử lý được cấu hình theo từng candidate: giữ hoặc loại English stopwords, tokenizer theo biểu thức chính quy, n-gram (1, 1) hoặc (1, 2) và giới hạn từ vựng. BoW/TF-IDF tạo ma trận thưa có số cột cố định, còn GloVe mean/IDF pooling tạo vector 50 chiều; vì vậy padding chuỗi không được áp dụng. Với GloVe, số token tối đa là 1.500 và số tài liệu bị cắt được ghi trong audit. Cách tổ chức này cho phép thay đổi tiền xử lý, biểu diễn và bộ phân loại độc lập trong cùng một pipeline.

Để giảm leakage, hai tin được nối cùng nhóm nếu có description hoặc company profile chuẩn hóa giống hệt nhau và đoạn dùng để nối dài ít nhất 80 ký tự. Phép nối có tính bắc cầu, tạo 4.699 nhóm; nhóm lớn nhất có 495 mẫu. Sau đó StratifiedGroupKFold với seed 42 được dùng để tạo tỷ lệ xấp xỉ 60/20/20 mà không tách một nhóm sang nhiều tập.

Nguy cơ	Biện pháp kiểm soát	Bằng chứng
Bản sao xuất hiện ở nhiều tập	Loại trùng văn bản chính xác, sau đó chia theo nhóm nội dung.	2.008 dòng bị loại; 4.699 nhóm.
Vocabulary nhìn thấy test	Fit vectorizer/vocabulary chỉ bằng train.	Kiểm tra train-only vocabulary đạt.
IDF/scaler nhìn thấy test	Fit bằng train rồi transform validation/test.	Checksum và manifest đặc trưng.
Chọn ngưỡng theo test	Tìm ngưỡng tối đa F1 trên validation, khóa trước test.	Cờ lựa chọn test bằng <i>false</i> .
Sai lệch thứ tự hàng	Mọi artifact dùng chung job ID, nhãn và split.	Kiểm tra alignment đạt.

Bảng 8: Các nguy cơ leakage và cơ chế kiểm soát

Quy tắc nhóm dựa trên chuỗi trùng chính xác không bắt được mọi paraphrase và cũng không đồng nghĩa với việc đã xác minh doanh nghiệp. Vì vậy báo cáo xem đây là biện pháp giảm leakage thực dụng, không tuyên bố loại bỏ tuyệt đối mọi quan hệ giữa các mẫu.



Hình 2: Phân bố độ dài văn bản và quy mô các tập chia

3.3 Các cấu hình được so sánh

Tổng cộng 26 cấu hình được chạy:

- BoW + MultinomialNB: $\alpha \in \{0,1;1,0\}$.
- TF-IDF unigram/bigram, có hoặc không stopwords + LR/SVM: $C \in \{0,5;2,0\}$.
- GloVe mean/IDF pooling + LR/SVM: $C \in \{0,1;1;10\}$.

Với mỗi cấu hình, ngưỡng quyết định được chọn trên validation nhằm tối đa F1 lớp gian lận. Mô hình cuối cùng được chọn theo F1 validation; nếu hòa, AP và thứ tự cấu hình được dùng làm tie-break. Chỉ sau khi khóa mô hình và ngưỡng, năm mô hình đại diện mới được đánh giá một lần trên test. Không dùng SMOTE hoặc cân bằng lại test.

3.4 Kết quả sàng lọc trên validation

Bảng 9 cho thấy quá trình chọn mô hình không chỉ so sánh tên thuật toán mà còn so sánh biểu diễn, regularization và ngưỡng. Các biến thể TF-IDF chiếm toàn bộ nhóm dẫn đầu; bigram nhìn chung cải thiện F1 so với unigram. Việc loại stopwords làm precision tăng ở một số cấu hình nhưng recall giảm, trong khi TF-IDF bigram không loại stopwords với SVM $C = 2$ đạt cân bằng tốt nhất.

ID	Biểu diễn	Mô hình	Tham số	Ngưỡng	F1	AP
0	BoW	NB	$\alpha = 0,1$	0,9984	0,5468	0,4639
3	TF-IDF unigram	SVM	$C = 0,5$	0,0045	0,6835	0,7030
5	TF-IDF unigram	SVM	$C = 2$	-0,2810	0,6842	0,7033
7	TF-IDF bigram	SVM	$C = 0,5$	-0,1701	0,6996	0,7157
9	TF-IDF bigram	SVM	$C = 2$	-0,3674	0,7076	0,7265
11	TF-IDF bigram+stop	SVM	$C = 0,5$	0,0344	0,6923	0,7099
13	TF-IDF bigram+stop	SVM	$C = 2$	-0,1110	0,6975	0,7195
14	GloVe mean	LR	$C = 0,1$	0,8205	0,3354	0,2376
21	GloVe IDF	SVM	$C = 0,1$	0,6155	0,3309	0,2283

Bảng 9: Một số cấu hình tiêu biểu trên validation

Bảng trên trình bày các cấu hình tiêu biểu. Kết quả đầy đủ của toàn bộ 26 cấu hình được lưu trong tệp `results/validation_scores.csv`. Thời gian fit riêng của cấu hình tốt nhất khoảng 1,56 giây sau khi đặc trưng đã được tạo, cho thấy pipeline tuyến tính vừa hiệu quả vừa tiết kiệm tài nguyên.

3.5 Mở rộng học sâu với TextCNN

TextCNN [10] sử dụng từ điển 30.000 token chỉ học từ train, chuỗi dài tối đa 300 token và embedding trainable 100 chiều. Ba nhánh tích chập có kernel 3, 4 và 5, mỗi nhánh 96 kênh, được nối sau global max pooling rồi qua dropout 0,5 và lớp sigmoid. Mô hình dùng AdamW [14], batch 128 và weighted binary cross-entropy để xử lý mất cân bằng. Epoch tốt nhất cùng ngưỡng quyết định được chọn theo F1 trên validation; test chỉ được đánh giá một lần sau khi khóa lựa chọn.

Thành phần	Cấu hình
Vocabulary	30.000 token, xây dựng chỉ từ train
Độ dài chuỗi	300 token, padding/truncation cố định
Embedding	100 chiều, học cùng mô hình
Convolution	Kernel 3/4/5, mỗi kernel 96 kênh
Pooling	Global max pooling theo thời gian
Regularization	Dropout 0,5
Tối ưu	AdamW, learning rate 0,001, batch 128
Loss	Weighted binary cross-entropy
Huấn luyện	Tối đa 6 epoch, seed 42

Bảng 10: Kiến trúc và siêu tham số TextCNN

Với chuỗi embedding $\mathbf{E} \in \mathbb{R}^{L \times d}$, mỗi bộ lọc một chiều quét qua các cửa sổ 3, 4 hoặc 5 token để tạo activation cục bộ. Global max pooling giữ tín hiệu mạnh nhất của mỗi kênh; ba vector pooling được nối và đưa qua dropout cùng một lớp tuyến tính. Khác GloVe pooling cố định, embedding và filter của TextCNN được cập nhật end-to-end từ nhãn train.

Trọng số dương của loss được tính từ tỷ lệ lớp train để hạn chế mô hình bỏ qua 427 mẫu gian lận. Sau mỗi epoch, score validation được dùng để tìm ngưỡng tối đa F1. Epoch 6 được chọn với loss train 0,1795, threshold 0,6019, F1 validation 0,5547 và AP 0,5659. Toàn bộ quá trình mất 176,58 giây trên CPU; test không tham gia quyết định epoch hoặc threshold.

Tập	Precision	Recall	F1	AP	TP/FP/FN/TN
Validation	0,6283	0,4965	0,5547	0,5659	71/42/72/2.990
Test khóa	0,5377	0,3986	0,4578	0,4890	57/49/86/2.983

Bảng 11: Kết quả lựa chọn và đánh giá TextCNN

3.6 Môi trường chạy và khả năng tái lập

Lần chạy lưu trong artifact sử dụng Python 3.14.4, scikit-learn 1.9.1 và PyTorch 2.14.0 trên Windows 11. Seed toàn cục là 42. Notebook standalone đã chạy đủ 10/10 code cells trong workspace sạch; bảy kiểm tra về ngữ nghĩa và artifact đã đạt. Checksum mã nguồn, dữ liệu, đặc trưng và thứ tự hàng được lưu để đối chiếu.

Khi chạy lại, notebook và lệnh dòng lệnh cùng đọc một cấu hình, cùng seed và cùng thứ tự dữ liệu đã lưu. Điều này giúp phân biệt sai khác do thay đổi mã nguồn hoặc dữ liệu với sai khác ngẫu nhiên của quá trình huấn luyện, đồng thời tạo điều kiện để kiểm tra lại các bảng và hình trong báo cáo.

Kiểm tra	Trạng thái	Ý nghĩa
Notebook trong workspace sạch	10/10 cell đạt	Không phụ thuộc file thủ công ngoài gói dự án.
Làm sạch HTML/missing text	Đạt	Tiền xử lý xử lý được dữ liệu thiếu và ký hiệu HTML.
Nhóm trùng bậc cầu	Đạt	Các phần tử liên thông không bị tách giữa các split.
Tối ưu ngưỡng	Đạt	Kết quả khớp tìm kiếm brute-force.
Căn chỉnh đặc trưng/nhãn	Đạt	Job ID, label, split và hàng đặc trưng đồng nhất.
Tính lại metrics	Đạt	Bảng báo cáo khớp dự đoán từng mẫu.
Vocabulary TextCNN train-only	Đạt	Không lấy token từ validation/test.
Demo và giải thích	Đạt	Từ đóng góp khớp chính xác phép tính mô hình tuyến tính.

Bảng 12: Các kiểm tra kỹ thuật đã chạy

Pipeline truyền thống mất 146,83 giây cho lần chạy đầy đủ đã lưu; notebook bao gồm cả phần học sâu chạy 277,21s trong workspace mới. Các con số này là thời gian tham chiếu trên máy kiểm tra, không phải cam kết tuyệt đối cho mọi môi trường. Mã nguồn không mount Google Drive, không yêu cầu API key hoặc tài khoản Kaggle và tải dữ liệu từ nguồn công khai.

4 Kết quả, so sánh và phân tích

4.1 Chọn mô hình trên validation


Cấu hình tốt nhất là TF-IDF unigram+bigram với Linear SVM, $C = 2,0$, $class_weight=balanced$, ngưỡng $-0,3674$. Trên validation, mô hình đạt precision 0,7313, recall 0,6853, F1 0,7076 và AP 0,7265. Việc khóa cấu hình này trước khi xem test giúp hạn chế việc chọn mô hình theo nhiều của tập test.

Ngưỡng âm được chọn trên validation vì điểm quyết định của Linear SVM không phải xác suất đã hiệu chuẩn. Lựa chọn này hướng đến cân bằng precision và recall của lớp gian lận thay vì tối đa hóa accuracy, vốn có thể tạo ấn tượng sai lệch khi số tin hợp lệ lớn hơn nhiều số tin gian lận.

4.2 Đánh giá cuối cùng trên tập test

Mô hình	Accuracy	Precision	Recall	F1	AP
Majority baseline	0,9550	0,0000	0,0000	0,0000	0,0450
BoW + NB	0,9458	0,3942	0,3776	0,3857	0,3321
TF-IDF + LR	0,9638	0,6556	0,4126	0,5064	0,5015
TF-IDF + SVM	0,9609	0,5714	0,5315	0,5507	0,5348
GloVe + LR	0,8907	0,1434	0,2867	0,1911	0,1374
GloVe + SVM	0,9162	0,1910	0,2657	0,2222	0,1424
TextCNN	0,9575	0,5377	0,3986	0,4578	0,4890

Bảng 13: So sánh kết quả test; precision, recall và F1 được tính cho lớp gian lận



Hình 3: So sánh F1 và average precision trên test

TF-IDF + SVM có F1 và AP cao nhất. TextCNN đạt F1 0,4578 và AP 0,4890: tốt hơn hai biến thể GloVe nhưng chưa vượt mô hình TF-IDF tuyến tính. Majority baseline đạt accuracy 95,50% nhưng không phát hiện được tin gian lận nào, cho thấy accuracy không phù hợp làm tiêu chí chính.

4.3 Độ ổn định từ validation sang test

Mô hình đại diện	F1 val.	F1 test	AP val.	AP test
BoW + NB	0,5468	0,3857	0,4639	0,3321
TF-IDF + LR	0,6667	0,5064	0,6771	0,5015
TF-IDF + SVM	0,7076	0,5507	0,7265	0,5348
GloVe + LR	0,3354	0,1911	0,2376	0,1374
GloVe + SVM	0,3309	0,2222	0,2283	0,1424
TextCNN	0,5547	0,4578	0,5659	0,4890


Bảng 14: So sánh validation và test của các mô hình đại diện

Tất cả mô hình đều giảm điểm khi chuyển sang test, vì vậy chỉ số validation không nên được trình bày như chất lượng triển khai. TF-IDF + SVM giảm F1 khoảng 0,157 nhưng vẫn giữ thứ hạng cao nhất; TextCNN giảm khoảng 0,097. Khoảng cách này có thể phản ánh dao động mẫu ở lớp hiếm, giới hạn của một validation duy nhất và sự khác biệt nhóm nội dung giữa hai tập.


4.4 Đánh đổi giữa mô hình, chất lượng và tài nguyên

TF-IDF + SVM là lựa chọn hợp lý nhất trong thí nghiệm hiện tại: F1/AP cao nhất, thời gian fit ngắn và mô hình chỉ khoảng 0,74 MB. TextCNN lớn hơn khoảng 12,47 MB và cần 176,58 giây huấn luyện CPU nhưng không vượt mô hình tuyến tính. GloVe tạo vector dense gọn song pooling 50 chiều làm mất nhiều tín hiệu. Kết quả này minh họa một nguyên tắc thực hành: độ phức tạp kiến trúc chỉ có giá trị khi chuyển thành cải thiện đo được dưới cùng một giao thức đánh giá.

4.5 Phân tích precision–recall và ma trận nhầm lẫn



Hình 4: Đường precision–recall của các mô hình đại diện



Hình 5: Ma trận nhầm lẫn của mô hình TF-IDF + Linear SVM

Mô hình dự đoán đúng 76 tin gian lận và 2.975 tin hợp lệ, đồng thời tạo 57 cảnh báo nhầm và bỏ sót 67 tin gian lận. Tỷ lệ bỏ sót 46,85% là đáng kể. Nếu triển khai thực tế, ngưỡng có thể được điều chỉnh theo chi phí của FN và FP, nhưng việc điều chỉnh phải dựa trên dữ liệu validation mới thay vì dùng lại test.

Đường precision-recall cho thấy đánh đổi giữa số cảnh báo đáng tin và số tin gian lận được phát hiện khi thay đổi ngưỡng. Ma trận nhầm lẫn bổ sung góc nhìn ở ngưỡng đã chọn: 57 FP làm tăng khối lượng rà soát, còn 67 FN là những trường hợp có thể không được cảnh báo. Hai hình vì thế cần được đọc cùng nhau, thay vì chỉ dựa vào một chỉ số tổng hợp.

4.6 Diễn giải kết quả so sánh biểu diễn

GloVe mean/IDF pooling nén toàn bộ tin tuyển dụng dài thành một vector 50 chiều. Cách tổng hợp này làm giảm ảnh hưởng của thứ tự từ, cấu trúc câu và các cụm từ hiếm nhưng có giá trị nhận diện. Trong khi đó, TF-IDF unigram+bigram vẫn giữ riêng trọng số cho từng từ và cụm từ xuất hiện trong văn bản; vì vậy các mẫu diễn đạt đặc trưng của một tin đăng có thể được Linear SVM khai thác trực tiếp.

Với dữ liệu tuyển dụng gồm nhiều trường văn bản được ghép lại, đặc trưng thưa có số chiều lớn là một lợi thế thực dụng. Linear SVM có thể đặt trọng số riêng cho các tín hiệu chỉ xuất hiện trong một lớp, còn GloVe pooling đưa nhiều token về cùng một đại diện trung bình nên các tín hiệu nhỏ dễ bị hòa lẫn. Ngoài ra, token ngoài từ điển GloVe và cách biểu diễn cố định không được fine-tune cũng có thể làm giảm lượng thông tin mà mô hình nhận được.

TextCNN học embedding cùng các bộ lọc n-gram trong quá trình huấn luyện nên giữ được nhiều cấu trúc cục bộ hơn GloVe pooling. Tuy nhiên, trên test khóa mô hình chỉ đạt precision 0,5377, recall 0,3986, F1 0,4578 và AP 0,4890; thấp hơn TF-IDF + SVM. Kết quả này cho thấy mô hình sâu không mặc nhiên tốt hơn khi dữ liệu gian lận ít, đồng thời cung cấp một phép so sánh trung thực thay vì chọn lại mô hình theo test.

4.7 Phân tích lỗi

Tập dự đoán chứa 15.875 hàng, tương ứng 3.175 mẫu cho mỗi mô hình đại diện. Riêng TF-IDF + SVM tạo 124 lỗi, gồm 57 false positive (FP) và 67 false negative (FN). Số FN cao hơn FP cho thấy mô hình vẫn có xu hướng bỏ sót một phần tin lừa đảo, dù accuracy tổng thể cao do lớp hợp lệ chiếm đa số.

Các FN thường là những tin được viết tương đối chuyên nghiệp, có mô tả công việc hợp lý hoặc không chứa rõ các cụm từ thường gợi ý gian lận. Khi đó, chỉ dựa vào văn bản đã ghép có thể chưa đủ: thông tin về lịch sử doanh nghiệp, tính nhất quán của địa chỉ liên hệ hay thời điểm đăng tin có thể cung cấp thêm ngữ cảnh. Đây cũng là nhóm lỗi cần được ưu tiên xem xét nếu hệ thống dùng để sàng lọc ban đầu cho người tìm việc.

Ngược lại, FP có thể xuất hiện ở các tin hợp lệ nhưng dùng ngôn ngữ tuyển dụng khẩn, quảng bá thu nhập hấp dẫn, làm việc từ xa hoặc có thông tin liên hệ không đầy đủ. Những dấu hiệu này chỉ là tương quan thống kê, không phải bằng chứng nhân quả. Vì vậy cho nên, nhân dự

đoán dương tính nên được chuyển sang bước kiểm tra thủ công thay vì tự động kết luận một tổ chức là lừa đảo.

Về vận hành, ngưỡng quyết định cần được chọn theo chi phí sai lầm. Nếu bỏ sót tin lừa đảo gây rủi ro cao, có thể hạ ngưỡng để tăng recall rồi chấp nhận thêm các trường hợp cần rà soát; nếu nguồn lực kiểm tra hạn chế, ngưỡng cao hơn sẽ giúp giảm FP. Phân tích trực tiếp các ví dụ FP/FN, hiệu chuẩn score và bổ sung đặc trưng có nguồn gốc rõ ràng là các bước tiếp theo cần thiết để cải thiện mô hình.

Job ID	Loại lỗi	Tiêu đề	Nhận xét
181	FN	Sales Executive	Văn bản cực ngắn và lặp tiêu đề; thiếu tín hiệu đủ mạnh để vượt ngưỡng.
844	FN	Technical & Customer Support Associates	Mô tả dài, chuyên nghiệp và giống tin hợp lệ nên mô hình bỏ sót.
846	FN	Service Associate	Cùng nhóm nội dung với job 844; cho thấy lỗi có thể tập trung theo chiến dịch đăng tin.
430	FP	Accounting Assistant	Tin hợp lệ có nhiều từ về xử lý hồ sơ, thanh toán và báo cáo, dễ gần với ngôn ngữ rủi ro.
442	FP	Account Manager/CSR	Chứa yêu cầu gửi hồ sơ qua email và thông tin quyền lợi, tạo tín hiệu cảnh báo nhầm.
616	FP	Telesales Advisor	Ngôn ngữ thu nhập hấp dẫn, lead và tuyển gấp khiến score vượt ngưỡng.

Bảng 15: Ví dụ lỗi của TF-IDF + Linear SVM trên tập test

Ba nhóm lỗi nổi bật là: văn bản quá ngắn; tin gian lận được viết chuyên nghiệp; và tin hợp lệ dùng ngôn ngữ quảng bá mạnh. Các trường hợp cùng group cũng nhắc rằng đơn vị lỗi không hoàn toàn độc lập theo từng dòng. Vì vậy, cải tiến tiếp theo nên đánh giá theo nhóm/doanh nghiệp và theo thời gian, đồng thời bổ sung cơ chế human-in-the-loop thay vì chỉ tối ưu thêm một vài phần trăm accuracy.

5 Demo, ứng dụng và giới hạn

5.1 Demo suy luận và giải thích

Dự án cung cấp demo nhận một tin tuyển dụng tiếng Anh, áp dụng đúng hàm làm sạch và vectorizer đã lưu, sau đó trả về score, nhãn cảnh báo và các cụm từ đóng góp mạnh nhất. Demo dùng TF-IDF + Logistic Regression vì score dễ diễn giải theo tổng đóng góp tuyến tính; mô hình demo có thể khác mô hình thắng chung cuộc nhưng vẫn được chọn trên validation và không huấn luyện lại khi nhập văn bản mới.

1. Người dùng nhập title, company profile, description, requirements và benefits hoặc một đoạn văn bản đã ghép.
2. Hệ thống chuẩn hóa HTML, URL/email và khoảng trắng bằng cùng pipeline huấn luyện.
3. Vectorizer đã khóa biến đổi văn bản; mô hình tính score và so với threshold validation.
4. Các n-gram có tích $x_j w_j$ lớn nhất được hiển thị như tín hiệu hỗ trợ đọc kết quả.

Phần giải thích chỉ mô tả đóng góp toán học của đặc trưng trong mô hình tuyến tính, không chứng minh quan hệ nhân quả. Demo từ chối đầu vào rỗng và chỉ load artifact do chính pipeline tạo ra. Trong triển khai thật, giao diện cần hiển thị rõ score chưa hiệu chuẩn, lý do cảnh báo và đường dẫn chuyển sang kiểm tra thủ công.

5.2 Kịch bản sử dụng đề xuất

Hệ thống phù hợp nhất với vai trò *xếp hạng ưu tiên rà soát*. Mỗi tin mới nhận một score; các tin score cao được đưa lên đầu hàng đợi cho chuyên viên, trong khi quyết định cuối vẫn thuộc về con người. Ngưỡng phải được điều chỉnh trên dữ liệu validation mới theo năng lực rà soát và chi phí FN/FP. Mọi quyết định, phiên bản mô hình và phản hồi người kiểm tra cần được ghi log để theo dõi drift.

5.3 Giới hạn và nguyên tắc sử dụng có trách nhiệm

1. **Dịch chuyển thời gian và ngôn ngữ:** EMSCAD là dữ liệu tiếng Anh 2012–2014; chưa đánh giá trên tiếng Việt hoặc các hình thức lừa đảo hiện nay.

2. **Nhãn và nhóm dữ liệu:** Nhãn có thể sai. Quy tắc nhóm dựa trên đoạn trùng chính xác không phát hiện mọi paraphrase và không bảo đảm có thể tách hoàn toàn theo doanh nghiệp thật.
3. **Validation hữu hạn:** Cùng một validation được dùng cho siêu tham số và ngưỡng; chưa thực hiện nested cross-validation.
4. **Điểm chưa hiệu chuẩn:** Score của SVM và xác suất logistic trong demo không đại diện xác suất gian lận thực tế.
5. **Rủi ro tác động:** Tự động chặn tin chỉ dựa trên mô hình có thể gây thiệt hại cho nhà tuyển dụng hợp lệ. Hệ thống nên ưu tiên hỗ trợ rà soát và cung cấp cơ chế khiếu nại.
6. **Quyền riêng tư:** Không nên bổ sung thuộc tính nhạy cảm của cá nhân nếu không có cơ sở pháp lý và đánh giá fairness phù hợp.

Demo chỉ nhận văn bản tiếng Anh trong phạm vi tương tự EMSCAD. Dự đoán không xác minh danh tính, không kết luận một tổ chức phạm pháp và không thay thế các nhận định và điều tra của con người.

6 Kết luận và hướng phát triển

Dự án đã xây dựng và kiểm định pipeline phân loại tin tuyển dụng lừa đảo có kiểm soát leakage, gồm 26 cấu hình truyền thống và một TextCNN học end-to-end. TF-IDF bigram + Linear SVM tiếp tục dẫn đầu trên test với F1 0,5507 và AP 0,5348; TextCNN đạt F1 0,4578 và AP 0,4890. Kết quả cho thấy mô hình sâu chưa vượt đặc trưng thưa trong dữ liệu hiện tại, còn recall 0,5315 của mô hình tốt nhất vẫn chưa đủ cho bộ lọc tự động độc lập.

Các hướng phát triển hợp lý gồm: thu thập dữ liệu mới và đa ngôn ngữ; đánh giá theo thời gian hoặc theo doanh nghiệp; hiệu chuẩn score; tối ưu ngưỡng theo chi phí; thử mô hình ngữ cảnh hiện đại trong một giao thức chống leakage tương đương; và đánh giá fairness, drift cùng chất lượng giải thích trước khi triển khai.

Câu hỏi	Kết luận từ thí nghiệm
RQ1	TF-IDF thưa phù hợp hơn GloVe pooling 50 chiều trên EMSCAD; F1 test 0,5507 so với 0,2222 của GloVe+SVM.
RQ2	Bigram không bỏ stopwords kết hợp SVM $C = 2$ cho cân bằng validation tốt nhất; ngưỡng tối ưu khác ngưỡng mặc định.
RQ3	TextCNN vượt GloVe nhưng chưa vượt TF-IDF; deep learning không tự động tốt hơn khi lớp dương ít.
RQ4	Lỗi tập trung ở văn bản ngắn, gian lận viết chuyên nghiệp và tin hợp lệ có ngôn ngữ quảng bá; cần rà soát con người.

Bảng 16: Câu trả lời cô đọng cho các câu hỏi nghiên cứu

Về mặt sản phẩm, dự án đáp ứng đầy đủ các thành phần bắt buộc của Bài 2: EDA, hai nhóm biểu diễn truyền thống/hiện đại, mô hình phân loại, lưu file đặc trưng, notebook Run all và báo cáo phân tích. TextCNN là phần mở rộng học sâu để so sánh công bằng, không được dùng để che khuất việc mô hình tuyến tính mới là kết quả tốt nhất. Toàn bộ kết luận đều dựa trên số liệu đã khóa và có thể tính lại từ file dự đoán.

7 Các đường link

- Mã nguồn GitHub: [duty00/job-scam-detection](#).
- Notebook Google Colab: [Mở notebook trên Google Colab](#).
- Báo cáo PDF: [Xem bản PDF trên GitHub](#).

TÀI LIỆU THAM KHẢO

Tài liệu

- [1] A. Vidros, C. Koliass, G. Kambourakis, and L. Akoglu, “Automatic Detection of Online Recruitment Frauds: Characteristics, Methods, and a Public Dataset,” *Future Internet*, vol. 9, no. 1, 2017.
- [2] J. Pennington, R. Socher, and C. D. Manning, “GloVe: Global Vectors for Word Representation,” *Proceedings of EMNLP*, 2014.
- [3] Scikit-learn Developers, “Model evaluation: quantifying the quality of predictions,” https://scikit-learn.org/stable/modules/model_evaluation.html.
- [4] S. Bhatt, “Real or Fake: Fake Job Posting Prediction,” Kaggle dataset mirror, <https://www.kaggle.com/datasets/shivamb/real-or-fake-fake-jobposting-prediction>.
- [5] S. Robertson, “Understanding Inverse Document Frequency: On Theoretical Arguments for IDF,” *Journal of Documentation*, vol. 60, no. 5, pp. 503–520, 2004.
- [6] A. McCallum and K. Nigam, “A Comparison of Event Models for Naive Bayes Text Classification,” *AAAI-98 Workshop on Learning for Text Categorization*, 1998.
- [7] T. Joachims, “Text Categorization with Support Vector Machines: Learning with Many Relevant Features,” *Proceedings of ECML*, pp. 137–142, 1998.
- [8] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [9] M. Sokolova and G. Lapalme, “A Systematic Analysis of Performance Measures for Classification Tasks,” *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009.
- [10] Y. Kim, *Convolutional Neural Networks for Sentence Classification*, Proceedings of EMNLP, 2014.
- [11] G. Salton and C. Buckley, *Term-Weighting Approaches in Automatic Text Retrieval*, Information Processing & Management, vol. 24, no. 5, pp. 513–523, 1988.
- [12] C. Cortes and V. Vapnik, *Support-Vector Networks*, Machine Learning, vol. 20, pp. 273–297, 1995.
- [13] T. Saito and M. Rehmsmeier, *The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets*, PLOS ONE, vol. 10, no. 3, 2015.
- [14] D. P. Kingma and J. Ba, *Adam: A Method for Stochastic Optimization*, Proceedings of ICLR, 2015.